

CORPORACIÓN UNIVERSITARIA MINUTO DE DIOS – UNIMINUTO

Fundamentos para IA

ANÁLISIS EXPLORATORIO DEL DATASET STUDENTS PERFORMANCE IN EXAMS

Actividad 2 – Consulta en un Dataset

Presentado por:

Johan Sebastián Cañon López - 730450

Juan David Cadavid Divantoque - 709493

Julio de 2026

1. Contexto representado por el dataset

El dataset Students Performance in Exams representa el rendimiento académico de 1.000 estudiantes en tres áreas: matemáticas, lectura y escritura. Además de los puntajes, incluye cinco variables de contexto: género, grupo étnico anonimizado, nivel educativo de los padres, tipo de almuerzo y participación en un curso de preparación. Por esta razón, el conjunto permite describir el desempeño y explorar asociaciones entre los resultados y algunas condiciones educativas o sociodemográficas.

2. Cinco variables importantes para describir el caso

Math score: mide el desempeño cuantitativo y presenta el rango más amplio de resultados.

Reading score: refleja la comprensión lectora y permite comparar el rendimiento en lenguaje.

Writing score: representa la producción escrita y se relaciona estrechamente con lectura.

Test preparation course: permite comparar a quienes completaron una preparación previa con quienes no la realizaron.

Lunch: aporta información contextual y presenta diferencias visibles entre sus categorías.

Las demás variables complementan la caracterización. En especial, género, grupo étnico y educación parental.

3. Hallazgos en la distribución de las variables

La muestra está casi equilibrada por género: 518 estudiantes son mujeres (51,8 %) y 482 hombres (48,2 %). El grupo C es el más frecuente dentro de la variable race/ethnicity, con 31,9 %, y el grupo A el menos representado, con 8,9 %. El 64,5 % recibe almuerzo estándar y el 35,5 % almuerzo gratuito o reducido. Frente a la preparación para el examen, 642 estudiantes (64,2 %) no completaron el curso y 358 (35,8 %) sí lo hicieron.

Variable	Promedio	Mediana	Desv. est.	Mínimo	Máximo
Math	66.09	66	15.16	0	100
Reading	69.17	70	14.60	17	100
Writing	68.05	69	15.20	10	100

Lectura obtiene el promedio más alto (69,17), seguida de escritura (68,05) y matemáticas (66,09). Las desviaciones estándar cercanas a 15 puntos muestran una dispersión similar en las tres asignaturas.

4. Relaciones relevantes entre las variables

La primera relación importante aparece entre los tres puntajes. Lectura y escritura presentan una correlación de 0,955, la más alta del conjunto. Matemáticas también se relaciona positivamente con lectura (0,818) y escritura (0,803). Esto indica que los estudiantes con resultados altos en una asignatura tienden a obtener resultados altos en las otras; sin embargo, la correlación no permite afirmar que una materia cause el desempeño de otra.

La segunda relación se observa en el curso de preparación. Quienes lo completaron alcanzaron promedios de 69,70 en matemáticas, 73,89 en lectura y 74,42 en escritura. Quienes no lo realizaron obtuvieron 64,08, 66,53 y 64,50, respectivamente. La diferencia más amplia aparece en escritura, con cerca de 9,91 puntos. El resultado sugiere una asociación favorable con la preparación, pero también podrían intervenir motivación, hábitos de estudio u otros factores que el dataset no registra.

También se identificaron diferencias según el tipo de almuerzo. El grupo con almuerzo estándar obtuvo promedios de 70,03 en matemáticas, 71,65 en lectura y 70,82 en escritura; el grupo con almuerzo gratuito o reducido alcanzó 58,92, 64,65 y 63,02. Las brechas son especialmente visibles en matemáticas. Esta variable puede reflejar condiciones de acceso a recursos, aunque el conjunto no ofrece información suficiente para establecer una explicación causal.

5. Calidad de los datos y forma de abordarla

No se encontraron valores nulos ni filas duplicadas. Los tres puntajes están dentro del intervalo de 0 a 100. La categoría none de test preparation course no corresponde a un dato faltante: significa que el estudiante no realizó el curso, por lo cual se conserva sin reemplazarla ni eliminarla.

Para detectar valores atípicos se aplicó el rango intercuartílico a math score. Se obtuvo $Q1 = 57$, $Q3 = 77$ e $IQR = 20$; por tanto, el límite inferior fue 27 y el superior 107. Se identificaron ocho puntajes bajos: 0, 8, 18, 19, 22, 23, 24 y 26.

La principal limitación es la ausencia de variables como edad, institución, asistencia, horas de estudio, resultados previos o fecha de evaluación.

6. Pregunta de Inteligencia Artificial o problema predictivo

A partir de la información disponible en el dataset, se podría plantear una pregunta como la siguiente: ¿es posible estimar el nivel de desempeño académico de un estudiante teniendo en cuenta algunas de sus características personales y educativas?

Para desarrollar esta idea se podrían utilizar variables como el género, el nivel educativo de los padres, el tipo de almuerzo y la participación en el curso de preparación. Estas variables podrían compararse con los resultados obtenidos en matemáticas, lectura y escritura.

El objetivo sería identificar si un estudiante presenta un desempeño bajo, medio o alto. De esta manera, la Inteligencia Artificial podría ayudar a reconocer patrones dentro de los datos y servir como apoyo para detectar estudiantes que posiblemente necesiten acompañamiento académico.

Sin embargo, los resultados de este análisis serían únicamente una aproximación, ya que el dataset no incluye otros aspectos importantes como la asistencia, los hábitos de estudio, la motivación, el entorno familiar o el desempeño anterior del estudiante. Por esta razón, una futura aplicación de Inteligencia Artificial debería utilizarse como una herramienta de apoyo y no como el único criterio para evaluar a una persona.

7. Conclusiones

El dataset presenta una calidad técnica adecuada para un análisis exploratorio: contiene 1.000 registros completos, no tiene duplicados y sus puntajes respetan el rango esperado. La media más alta corresponde a lectura y la menor a matemáticas. La relación más fuerte se da entre lectura y escritura, mientras que el curso de preparación y el tipo de almuerzo muestran diferencias descriptivas en los promedios.

Los valores atípicos bajos deben conservarse mientras no exista evidencia de error. El conjunto puede servir como base para un prototipo de clasificación de riesgo académico, siempre que se reconozcan las variables omitidas, se revisen posibles sesgos y las decisiones finales permanezcan bajo supervisión humana.

8. NoteBook Jupyter

<https://anaconda.com/app/share/notebooks/6e450c09-bd27-4b58-9c9a-75a7ce12a018/overview>

Bibliografía

Corporación Universitaria Minuto de Dios – UNIMINUTO. (s. f.). Anexo: Consulta en un Dataset. Fundamentos para IA.

S P Scientist. (s. f.). Students Performance in Exams [Conjunto de datos]. Kaggle.

Boschetti, A. y Massaron, L. (2018). Python Data Science Essentials: A Practitioner's Guide Covering Essential Data Science Principles, Tools, and Techniques [Links to an external site.](#) (10-35). Packt Publishing, Limited.

So, A., Joseph, T. V., John, R. T., Worsley, A. y Asare, S. (2020). The data science workshop: A new, interactive approach to learning data science. [Links to an external site.](#) (pp. 16-36) Packt Publishing, Limited.

Mert, U., y Cuhadaroglu, M. (2018). Mastering numerical computing with NumPy: Master scientific computing and perform complex operations with ease [Links to an external site.](#) (55-87). Packt Publishing, Limited.