

# ESTUDIO DE CASO: CONSULTA EN UN DATASET MEDIANTE PYTHON PARA CIENCIA DE DATOS

**Asignatura:** Fundamentos para IA

**Especialización en Inteligencia Artificial Corporación Universitaria Minuto de Dios (UNIMINUTO)**

**Fecha:** Julio de 2026

## 1. Objeto de Estudio

El presente estudio de caso se enfoca en el análisis exploratorio y la evaluación de la calidad de un conjunto de datos estructurado que registra el rendimiento académico de los estudiantes en tres áreas fundamentales: matemáticas, lectura y redacción. El problema central radica en comprender cómo los factores demográficos, las condiciones de preparación académica previa y el entorno socioeconómico influyen de manera directa o indirecta en los resultados de las evaluaciones cuantitativas.

A través de la utilización del lenguaje de programación Python, se aborda la necesidad de procesar un archivo en formato de valores separados por comas (CSV). El análisis se centra en examinar las interrelaciones existentes entre las variables categóricas (como el nivel educativo de los padres o la realización de cursos de preparación) y las variables numéricas (las calificaciones obtenidas), con el fin de identificar patrones de comportamiento, brechas de rendimiento y oportunidades de intervención educativa mediante técnicas analíticas avanzadas.

## 2. Actores y Contextos

El ecosistema del problema involucra a múltiples actores y un entorno tecnológico específico que facilita el procesamiento de la información:

- **Actores Involucrados:**
  - **Los Estudiantes:** Sujetos principales del estudio, de quienes se extraen las métricas de desempeño y las condiciones sociodemográficas asociados a su entorno.

- **Los Padres o Tutores:** Actores indirectos clave, cuyo nivel de formación académica constituye una variable del entorno familiar que impacta el desempeño del estudiante.
- **Las Instituciones Educativas y Diseñadores de Currículo:** Entidades interesadas en los hallazgos para optimizar los programas de apoyo, implementar cursos de preparación efectivos y diseñar estrategias predictivas de retención o nivelación académica.
- **Contexto Tecnológico:**
  - **Python:** Lenguaje de programación de código abierto seleccionado debido a su robustez, escalabilidad y ecosistema maduro para la manipulación de datos.
  - **Pandas:** Biblioteca de código abierto esencial para la ciencia de datos en Python, empleada para la carga, estructuración, limpieza, filtrado y transformación del dataset en un objeto tipo *DataFrame*.
  - **NumPy:** Biblioteca matemática utilizada para el soporte de vectores y matrices multidimensionales, así como para la ejecución de funciones estadísticas y cálculos numéricos de alta eficiencia.
  - **Entorno de Ejecución (Notebook):** Uso de plataformas interactivas como Google Colab o Jupyter Notebook, las cuales permiten combinar celdas de código ejecutable con documentación narrativa, facilitando la reproducibilidad del análisis.

### 3. Objetivos del Estudio de Caso

- **Aplicación Tecnológica:** Implementar scripts en Python utilizando las librerías Pandas y NumPy para automatizar la lectura, visualización inicial y manipulación del dataset de rendimiento estudiantil.
- **Exploración y Caracterización:** Analizar de manera exhaustiva la estructura del archivo CSV, detallando las dimensiones del dataset, los tipos de variables presentes y sus respectivas escalas de medición.

- **Diagnóstico de Calidad:** Evaluar la integridad del conjunto de datos mediante la detección sistemática de valores faltantes, registros duplicados y la identificación analítica de valores atípicos.
- **Interpretación de Resultados:** Analizar las frecuencias de las variables categóricas y las estadísticas descriptivas de las numéricas para descubrir tendencias, correlaciones latentes y proponer preguntas predictivas orientadas a la Inteligencia Artificial.

#### 4. Informe Final y Respuestas al Cuestionario

##### a. ¿Qué fenómeno, proceso o contexto representa el dataset?

El conjunto de datos representa el **rendimiento académico en pruebas estandarizadas de educación secundaria** y su relación con el entorno social, familiar y económico del alumno. Captura un proceso de evaluación cuantitativa (puntuaciones de 0 a 100) contextualizado por factores demográficos y de preparación, lo que permite analizar el fenómeno de la educación desde una perspectiva multivariable, identificando si el éxito académico está ligado exclusivamente a la capacidad del estudiante o si está condicionado por variables externas preexistentes.

##### b. ¿Cuáles son las 5 variables más importantes para describir el caso y por qué?

1. **math score / reading score / writing score (Calificaciones):** Se agrupan como el núcleo del estudio. Son variables numéricas continuas que representan el rendimiento real obtenido y actúan como las variables de respuesta u objeto de predicción.
2. **parental level of education (Nivel educativo de los padres):** Es una variable categórica ordinal de vital importancia, ya que funciona como un indicador del capital cultural y socioeconómico dentro del hogar, permitiendo evaluar si el grado académico de los padres correlaciona con las metas alcanzadas por los hijos.
3. **test preparation course (Curso de preparación):** Variable categórica binaria ("completed" o "none"). Es crítica porque mide el impacto directo de una acción educativa deliberada sobre los puntajes, sirviendo para demostrar si el entrenamiento previo mitiga las deficiencias académicas.

4. **lunch (Almuerzo):** Variable categórica que indica si el estudiante recibe almuerzo estándar o reducido/gratuito. Funciona como una variable *proxy* o indicador indirecto del nivel de ingresos económicos del núcleo familiar, permitiendo analizar brechas asociadas a la vulnerabilidad socioeconómica.
5. **gender (Género):** Variable categórica binaria esencial para realizar análisis demográficos y determinar si existen sesgos o diferencias estadísticamente significativas en el rendimiento por asignaturas (por ejemplo, si un género sobresale en habilidades cuantitativas frente a las verbales).

c. ¿Qué hallazgos se observan en la distribución de variables (categóricas y numéricas)?

- **Distribución de Variables Categóricas:** Al aplicar la función `value_counts(normalize=True) * 100` en Python, se observa que la variable `gender` presenta una distribución bastante equilibrada, con aproximadamente un 51.8% de participación femenina y un 48.2% masculina. En contraste, la variable `test preparation course` revela que la gran mayoría de los estudiantes (cerca del 64.2%) asistió a los exámenes sin haber completado ningún curso de preparación, lo que expone una clara falta de acompañamiento o incentivo institucional previo.
- **Distribución de Variables Numéricas:** Al ejecutar el método `.describe()`, se evidencia que las tres variables de calificación poseen un comportamiento que se aproxima a una distribución normal. El promedio general de las pruebas oscila en un rango medio-alto: la media en lectura es de ~69.1 puntos, en redacción es de ~68.0 puntos, mientras que matemáticas registra la media más baja con ~66.0 puntos. Esto sugiere que el área cuantitativa presenta un nivel de complejidad superior o una mayor dispersión en el aprendizaje para este grupo de estudiantes.

d. ¿Qué relación relevante encontraron entre las variables? (Mínimo 2)

1. **Relación entre el Curso de Preparación y el Rendimiento:** Al agrupar los datos, los estudiantes que completaron el `test preparation course` obtuvieron promedios notablemente más altos en las tres áreas evaluadas. En matemáticas, por ejemplo, el grupo con curso de preparación superó por más de 7 puntos en promedio al grupo que no se preparó, demostrando que la preparación formal tiene una incidencia positiva y medible en los resultados académicos.

2. **Relación entre el Nivel Educativo Parental y el Éxito Escolar:** Se identificó una correlación directa y proporcional entre el grado de escolaridad de los padres y las calificaciones de los alumnos. Los estudiantes cuyos padres poseen títulos de posgrado o licenciaturas (*Master's degree* o *Bachelor's degree*) obtuvieron las medianas de calificación más altas del dataset, mientras que aquellos cuyos padres únicamente culminaron la escuela secundaria (*High School*) registraron los promedios más bajos, reflejando cómo el entorno educativo del hogar perpetúa o favorece el rendimiento académico.

e. ¿Qué problemas de calidad de datos detectaron y cómo los abordan?

- **Integridad y Vacíos:** Tras aplicar la instrucción `df.isnull().sum()` en Python, se determinó que el dataset cuenta con 0 valores nulos, lo que significa que posee una excelente integridad estructural inicial. De igual forma, el conteo de duplicados arrojó un valor de cero registros idénticos. En caso de haber detectado valores nulos en un escenario real, la estrategia metodológica adecuada habría sido la imputación mediante la mediana para conservar la robustez estadística sin sesgar la distribución.
- **Valores Atípicos (Outliers):** Al evaluar la variable numérica math score utilizando la regla del Rango Intercuartílico ( $IQR = Q3 - Q1$ ), se identificaron algunos valores atípicos en el extremo inferior (estudiantes con puntajes extremadamente bajos o cercanos a cero). El abordaje analítico consistió en **no eliminar** estos registros. En el contexto de la ciencia de datos aplicada a la educación, un puntaje críticamente bajo no es un error de digitación, sino un dato real y valioso que representa un caso de reprobación extrema o deserción académica latente que los modelos predictivos deben aprender a identificar.

f. Con base en lo observado: ¿qué pregunta de IA o problema predictivo podría plantearse a futuro con este dataset?

- **Enfoque de Regresión (Predicción Numérica):** *¿Es posible predecir con precisión la calificación que obtendrá un estudiante en el examen de matemáticas basándose en sus puntajes de lectura, redacción y su entorno socioeconómico?* Este planteamiento permitiría entrenar un algoritmo de regresión lineal o un bosque aleatorio (*Random Forest Regressor*) para estimar el rendimiento cuantitativo antes de realizar la prueba física.

- **Enfoque de Clasificación Binaria (Modelado Preventivo):** *¿Podemos clasificar de manera automatizada si un estudiante pertenece al grupo de "Alto Riesgo de Reprobación" (puntaje menor a 60) utilizando sus variables sociodemográficas y su historial de preparación?* Al formular esto como un problema de clasificación supervisada, la institución de educación podría implementar un sistema de alerta temprana que identifique automáticamente a los alumnos vulnerables en las primeras semanas del ciclo académico para asignarles tutorías personalizadas obligatorias antes de los exámenes finales.

## 5. Bibliografía

- Boschetti, A. y Massaron, L. (2018). *Python Data Science Essentials: A Practitioner's Guide Covering Essential Data Science Principles, Tools, and Techniques* (pp. 10-35). Packt Publishing, Limited.
- Mert, U., y Cuhadaroglu, M. (2018). *Mastering numerical computing with NumPy: Master scientific computing and perform complex operations with ease* (pp. 55-87). Packt Publishing, Limited.
- So, A., Joseph, T. V., John, R. T., Worsley, A. y Asare, S. (2020). *The data science workshop: A new, interactive approach to learning data science* (pp. 16-36). Packt Publishing, Limited.

Enlace público del Notebook (Colab o Jupyter) con permisos de visualización habilitados

[https://colab.research.google.com/drive/105SUougCScAL1zurqcG\\_so7z5R8Pnne?usp=s\\_haring](https://colab.research.google.com/drive/105SUougCScAL1zurqcG_so7z5R8Pnne?usp=s_haring)