

Estudio de caso. Consulta en un Dataset

Dataset: Students Performance

Estudiantes: José Eduardo Martínez Orrego y Juan Felipe Rueda Orrego

Curso: Fundamentos para IA

Docente: CESAR ALFONSO BOLADO SILVA

12 de julio de 2026

Corporación Universitaria Minuto de Dios – UNIMINUTO

1. Introducción

El análisis exploratorio de datos constituye una etapa fundamental en los proyectos de ciencia de datos, ya que permite comprender la estructura de la información, evaluar su calidad e identificar patrones antes de desarrollar modelos de inteligencia artificial. En este estudio se analizó el conjunto de datos *Students Performance* mediante Python, utilizando Visual Studio Code y las bibliotecas Pandas, NumPy y Matplotlib, con el propósito de explorar las características de las variables, verificar la calidad de la información e identificar posibles relaciones entre factores personales, familiares y el rendimiento académico. Este proceso permitió aplicar conceptos básicos de ciencia de datos y reconocer la importancia del análisis exploratorio como base para futuros modelos de clasificación o regresión orientados a predecir el desempeño de los estudiantes.

2. Objeto de estudio

El presente estudio de caso analiza el rendimiento académico de los estudiantes a partir del conjunto de datos *Students Performance*, con el propósito de identificar relaciones entre variables personales, familiares y educativas y los resultados obtenidos en matemáticas, lectura y escritura. Para ello se utilizó Python como herramienta de análisis, lo que permitió explorar la estructura de la información, evaluar su calidad e interpretar el comportamiento de las variables como etapa previa al desarrollo de modelos de clasificación o regresión.

3. Actores y contexto

En este estudio participaron los estudiantes representados en el conjunto de datos, quienes constituyeron la fuente de información, y los analistas encargados de explorar, interpretar y evaluar la calidad de los datos. El análisis se desarrolló en Python mediante Visual Studio Code, utilizando las bibliotecas Pandas, NumPy y Matplotlib para leer el archivo CSV, examinar su estructura, identificar posibles problemas de calidad y analizar las relaciones entre las variables, como parte de la fase exploratoria previa al desarrollo de modelos de inteligencia artificial.

4. Objetivos

Objetivo general

Analizar el dataset Students Performance mediante herramientas de Ciencia de Datos en Python para comprender su estructura, evaluar la calidad de los datos e identificar relaciones entre las variables como base para futuros modelos de Inteligencia Artificial.

Objetivos específicos

- Explorar el conjunto de datos mediante Python para conocer su estructura, características y tipos de variables.
- Evaluar la calidad de la información mediante la identificación de valores nulos, registros duplicados y valores atípicos.
- Analizar e interpretar el comportamiento y las relaciones entre las variables mediante estadísticas descriptivas y representaciones gráficas, como base para futuros modelos de clasificación o regresión.

5. Comprensión de variables

El dataset Students Performance contiene 1.000 registros y 8 variables, clasificadas en categóricas y numéricas. Esta combinación permite analizar las características de los estudiantes y su relación con el rendimiento académico.

A continuación, se presenta la descripción de las variables incluidas en el conjunto de datos.

Tabla 1: Descripción de las variables del dataset Students Performance

Variable	Tipo	Descripción	Importancia para el análisis
gender	Categórica	Género del estudiante.	Compara el rendimiento entre grupos.
race/ethnicity	Categórica	Grupo étnico.	Analiza diferencias poblacionales.
parental level of education	Categórica	Nivel educativo de los padres.	Evalúa la influencia del entorno familiar.
lunch	Categórica	Tipo de alimentación.	Refleja condiciones socioeconómicas.

Variable	Tipo	Descripción	Importancia para el análisis
test preparation course	Categorica	Curso de preparación.	Analiza su efecto sobre el rendimiento.
math score	Numérica	Puntaje en matemáticas.	Mide el rendimiento académico.
reading score	Numérica	Puntaje en lectura.	Evalúa la comprensión lectora.
writing score	Numérica	Puntaje en escritura.	Evalúa la expresión escrita.

Las variables categóricas permiten comparar grupos de estudiantes según sus características personales y familiares, mientras que las variables numéricas describen el desempeño académico mediante medidas estadísticas. En conjunto, estas variables proporcionan una base adecuada para realizar análisis exploratorios y desarrollar futuros modelos de clasificación o regresión.

6. Diagnóstico de calidad de datos

La calidad de los datos se evaluó mediante Python, verificando la presencia de valores nulos, registros duplicados y valores atípicos. Los resultados mostraron que el conjunto de datos no contiene valores nulos ni registros repetidos, por lo que no fue necesario aplicar procesos adicionales de limpieza. En la variable *math score* se identificaron algunos valores atípicos mediante el método del rango intercuartílico y un diagrama de caja; sin embargo, después de revisarlos, se determinó que correspondían a observaciones válidas y se conservaron dentro del análisis. En términos generales, el conjunto de datos presenta una calidad adecuada para realizar análisis descriptivos y constituye una base confiable para futuras aplicaciones de inteligencia artificial.

Tabla 2: Resumen del análisis exploratorio del dataset Students Performance

Indicador	Resultado	Interpretación
Número de registros	1.000	Tamaño suficiente para un análisis exploratorio.
Número de variables	8	Incluye variables categóricas y numéricas.
Valores nulos	0	No fue necesario imputar datos.

Indicador	Resultado	Interpretación
Registros duplicados	0	No se identificaron observaciones repetidas.
Valores atípicos	Presentes en math score	Se conservaron por corresponder a datos reales.
Variable con mayor promedio	Reading score (69,17)	Presentó el mejor desempeño promedio.
Variables con mayor relación	Reading score y Writing score (r=0.95)	Se observó una asociación positiva entre ambas.

7. Análisis por variable

El análisis exploratorio permitió identificar patrones relevantes en las variables categóricas y numéricas del conjunto de datos. Se observó una distribución equilibrada entre estudiantes femeninos y masculinos, el predominio de la categoría *standard* en la variable *lunch* y una mayor proporción de estudiantes que no completó el curso de preparación para exámenes. Asimismo, quienes realizaron dicho curso obtuvieron mejores resultados en matemáticas, lectura y escritura. En cuanto a las variables numéricas, lectura presentó el promedio más alto, seguida de escritura y matemáticas, y se identificó una relación positiva entre los puntajes de lectura y escritura. Estos hallazgos indican que el curso de preparación, el tipo de alimentación y el nivel educativo de los padres son variables de interés para futuros modelos de clasificación o regresión orientados a predecir el rendimiento académico.

8. Preguntas del informe final

a. ¿Qué fenómeno, proceso o contexto representa el dataset?

El dataset representa el rendimiento académico de los estudiantes mediante sus resultados en matemáticas, lectura y escritura, junto con variables personales y familiares asociadas a su desempeño.

b. ¿Cuáles son las 5 variables más importantes para describir el caso y por qué?

Las variables más relevantes son math score, reading score y writing score, porque representan el desempeño académico de los estudiantes. También destacan test

preparation course, debido a su relación con mejores resultados, y parental level of education, ya que permite analizar la influencia del contexto familiar sobre el rendimiento académico.

c. ¿Qué hallazgos se observan en la distribución de variables?

La distribución de las variables categóricas permitió comparar adecuadamente los diferentes grupos de estudiantes. En las variables numéricas se observó que los puntajes de lectura y escritura presentan promedios superiores a los de matemáticas. También se identificaron algunos valores atípicos en matemáticas, aunque estos corresponden a observaciones válidas.

d. ¿Qué relación relevante encontraron entre las variables?

El análisis mostró que los estudiantes que completaron el curso de preparación obtuvieron mejores resultados académicos. También se observó una relación positiva entre lectura y escritura, además de diferencias en el rendimiento según el tipo de alimentación, lo que evidencia asociaciones que podrían analizarse mediante modelos predictivos.

e. ¿Qué problemas de calidad de datos detectaron y cómo los abordaron?

No se identificaron valores nulos ni registros duplicados. Los valores atípicos encontrados en matemáticas fueron revisados y se conservaron al considerarse observaciones reales, por lo que no fue necesario aplicar procesos adicionales de limpieza de datos.

f. ¿Qué pregunta de IA o problema predictivo podría plantearse a futuro?

Una aplicación futura consiste en desarrollar un modelo de clasificación que identifique estudiantes con riesgo de bajo rendimiento académico a partir de variables personales y socioeducativas. También podría implementarse un modelo de regresión para estimar los puntajes obtenidos en las diferentes áreas evaluadas.

9. Conclusiones

El análisis del conjunto de datos *Students Performance* permitió evaluar la calidad de la información e identificar relaciones entre sus variables mediante Python. Los resultados mostraron asociaciones entre el rendimiento académico, el curso de preparación, el tipo de alimentación y el nivel educativo de los padres, además de una correlación positiva entre lectura y escritura. En conclusión, el conjunto de datos es adecuado para análisis descriptivos y futuros modelos predictivos.

10. Anexo

Enlace al Notebook

El notebook desarrollado para este estudio de caso se encuentra disponible en el siguiente enlace: <https://colab.research.google.com/drive/1ROAjcePOtbpwZIFWQ7xMnjip-3f3bOVw?usp=sharing>

11. Referencias

Boschetti, A., & Massaron, L. (2018). *Python Data Science Essentials: A Practitioner's Guide Covering Essential Data Science Principles, Tools, and Techniques*. Packt Publishing.

So, A., Joseph, T. V., John, R. T., Worsley, A., & Asare, S. (2020). *The Data Science Workshop: A New, Interactive Approach to Learning Data Science*. Packt Publishing.

Seshapanpu, J. (2019). *Students Performance in Exams*. Kaggle.