

**ESTUDIO DE CASO: ANÁLISIS EXPLORATORIO DEL RENDIMIENTO ACADÉMICO
DE ESTUDIANTES MEDIANTE PYTHON**

JUAN DAVID RAMÍREZ HENAO

Universidad UNIMINUTO
Especialización en Inteligencia Artificial
2026

Docente
CESAR ALFONSO BOLADO SILVA

Introducción

En la actualidad, el análisis de datos se ha convertido en una herramienta fundamental para comprender el comportamiento de la información y apoyar la toma de decisiones en diferentes áreas del conocimiento. En el ámbito educativo, el estudio de variables relacionadas con el rendimiento académico permite identificar patrones que contribuyen a comprender los factores que pueden influir en el desempeño de los estudiantes.

El presente estudio de caso tiene como finalidad aplicar conceptos básicos de análisis de datos utilizando Python y algunas de sus principales bibliotecas para ciencia de datos. A partir del conjunto de datos **Students Performance**, se realizó un proceso de exploración, validación de la calidad de la información y análisis descriptivo de las variables, con el propósito de identificar tendencias y relaciones entre las características de los estudiantes y los resultados obtenidos en las pruebas de matemáticas, lectura y escritura.

Finalmente, el desarrollo de esta actividad permitió fortalecer el manejo de herramientas como Pandas, Matplotlib y Seaborn, así como comprender la importancia del análisis exploratorio de datos como etapa previa al desarrollo de modelos de Inteligencia Artificial y aprendizaje automático.

Objeto del estudio

Este estudio de caso tiene como objetivo examinar un conjunto de datos sobre el rendimiento académico de estudiantes en tres áreas: matemáticas, lectura y escritura. Además de los puntajes, el conjunto de datos incluye variables relacionadas con el contexto del estudiante, como el género, el grupo étnico, el nivel educativo de los padres, el tipo de almuerzo que reciben y si han tomado un curso de preparación para el examen. El objetivo del análisis es identificar posibles relaciones entre estas variables y el desempeño académico, usando Python y bibliotecas especializadas para procesar y analizar los datos.

Actores y contexto

El actor principal del estudio son los estudiantes. El conjunto de datos registra su desempeño académico en matemáticas, lectura y escritura. También incluye características como el género, el tipo de alimentación, la realización de un curso de preparación y el nivel educativo de sus padres. Además, los padres o cuidadores son actores importantes, ya que su nivel de formación puede afectar el rendimiento académico de los estudiantes. Esto forma parte de las variables analizadas.

El analista de datos también participa en el proceso de análisis. Él es responsable de procesar la información, verificar su calidad e interpretar los resultados. Para el desarrollo del estudio se utilizó Python 3.12 como lenguaje de programación. Se trabajó en Jupyter Notebook y se usaron las bibliotecas Pandas para manipular datos, Matplotlib y Seaborn para crear gráficos. Todo esto se ejecutó desde Visual Studio Code como entorno de desarrollo.

Objetivo general

Analizar el conjunto de datos Students Performance usando Python y sus bibliotecas para ciencia de datos. Esto permitirá explorar las características del dataset, evaluar la calidad de la información e identificar tendencias y relaciones entre las variables que puedan explicar el desempeño académico de los estudiantes.

Informe final

4.1 Comprensión de las variables

4.1.1 Diccionario de datos

El conjunto de datos está conformado por ocho variables que describen tanto características del contexto de los estudiantes como sus resultados académicos. Cinco de estas variables son de tipo categórico y permiten identificar condiciones personales o familiares del estudiante, mientras que las tres restantes son variables numéricas correspondientes a los puntajes obtenidos en matemáticas, lectura y escritura.

La variable **gender** identifica el género del estudiante. **Race/ethnicity** clasifica a los estudiantes en diferentes grupos poblacionales definidos en el dataset. **Parental level of education** registra el nivel educativo alcanzado por los padres o acudientes. **Lunch** indica el tipo de alimentación recibida por el estudiante, mientras que **test preparation course** informa si el estudiante completó o no un curso de preparación antes de presentar la evaluación.

Las variables **math score**, **reading score** y **writing score** representan los puntajes obtenidos por cada estudiante en las áreas de matemáticas, lectura y escritura, respectivamente. Estas tres variables constituyen el principal indicador del rendimiento académico y son el eje central del análisis realizado.

4.1.2 Variables más importantes

Aunque todas las variables aportan información al estudio, se consideran especialmente relevantes las siguientes:

Math score, debido a que representa el desempeño del estudiante en el área de matemáticas y permite evaluar diferencias en el rendimiento académico.

Reading score, ya que refleja la capacidad de comprensión lectora y facilita la comparación con las demás áreas evaluadas.

Writing score, porque complementa el análisis del desempeño académico y permite identificar comportamientos similares o diferentes respecto a matemáticas y lectura.

Test preparation course, debido a que permite establecer si la realización de un curso de preparación tiene alguna relación con los resultados obtenidos por los estudiantes.

Parental level of education, ya que ofrece información sobre el contexto familiar del estudiante y permite analizar si existe alguna tendencia entre el nivel educativo de los padres y el desempeño académico.

4.2 Diagnóstico de la calidad de los datos

Antes de realizar cualquier análisis estadístico, se evaluó la calidad del conjunto de datos con el propósito de verificar que la información fuera consistente y adecuada para el desarrollo del estudio. Para ello, se revisó la estructura del dataset, la presencia de valores nulos, la existencia de registros duplicados y la posible aparición de valores atípicos en las variables numéricas.

Como resultado de la exploración inicial, se identificó que el conjunto de datos está conformado por **1.000 registros y 8 variables**, de las cuales cinco corresponden a variables categóricas y tres a variables numéricas. Además, se comprobó que todas las columnas contienen información completa, ya que cada una registra los 1.000 valores esperados, sin evidenciar datos faltantes.

Posteriormente, se realizó la validación de valores nulos mediante las funciones de Pandas, encontrándose que ninguna de las variables presenta datos vacíos. Esto indica que el dataset se encuentra completo y no fue necesario aplicar técnicas de imputación o eliminación de registros por ausencia de información.

De igual manera, se verificó la existencia de registros duplicados y se confirmó que no existen filas repetidas dentro del conjunto de datos. Este resultado permite trabajar con la totalidad de los registros sin necesidad de realizar procesos de depuración relacionados con duplicidad de información.

Finalmente, se analizaron las variables numéricas mediante diagramas de caja (Boxplot) para identificar posibles valores atípicos. Durante esta revisión se observaron algunos puntajes alejados del comportamiento general de los datos, especialmente en la variable correspondiente a matemáticas. Sin embargo, estos valores representan calificaciones reales obtenidas por algunos estudiantes y no evidencian errores de captura o inconsistencias en la información. Por esta razón, se decidió conservarlos dentro del análisis, ya que hacen parte del comportamiento natural del conjunto de datos y aportan información relevante sobre la variabilidad del rendimiento académico.

4.3 Análisis por variable

4.3.1 Variable categórica: Género (gender)

La variable **gender** corresponde a una variable categórica nominal que clasifica a los estudiantes según su género. Al analizar su distribución mediante frecuencias y porcentajes, se observa que el conjunto de datos presenta una participación relativamente equilibrada entre estudiantes de género masculino y femenino, sin diferencias marcadas entre ambos grupos. Esta distribución favorece el análisis posterior, ya que permite realizar comparaciones entre los resultados académicos sin que exista un desbalance importante en la cantidad de registros de cada categoría.

4.3.2 Variable categórica: Curso de preparación (test preparation course)

La variable **test preparation course** indica si el estudiante completó un curso de preparación antes de presentar la evaluación. El análisis de frecuencias muestra que la mayor parte de los estudiantes no realizó dicho curso, mientras que una proporción menor sí lo completó. Esta variable resulta especialmente relevante porque posteriormente permitirá analizar si existe alguna relación entre la preparación previa y el desempeño obtenido en las diferentes áreas evaluadas.

4.3.3 Variable numérica: Puntaje en matemáticas (math score)

La variable **math score** representa el puntaje obtenido por cada estudiante en el área de matemáticas. El análisis descriptivo muestra un promedio cercano a 66 puntos y una mediana de 66, lo que indica que la distribución de los datos presenta una tendencia central estable. Los valores registrados oscilan entre 0 y 100 puntos y la desviación estándar evidencia una dispersión moderada entre los resultados de los estudiantes. Durante la revisión también se identificaron algunos valores atípicos; sin embargo, estos corresponden a puntajes reales y fueron conservados dentro del análisis.

4.3.4 Variable numérica: Puntaje en lectura (reading score)

La variable **reading score** presenta un comportamiento similar al observado en matemáticas. El promedio se ubica alrededor de 69 puntos y la mediana alcanza los 70 puntos, lo que refleja una distribución relativamente equilibrada. Los puntajes abarcan un rango entre 17 y 100 puntos y la desviación estándar indica una variabilidad moderada en el desempeño de los estudiantes. En comparación con matemáticas, los resultados de lectura presentan un promedio ligeramente superior.

4.4 Relación entre variables

4.4.1 Relación entre el curso de preparación y el rendimiento académico

Al comparar los puntajes promedio obtenidos por los estudiantes según la variable **test preparation course**, se observó que quienes completaron el curso de preparación obtuvieron mejores resultados en matemáticas, lectura y escritura frente a quienes no realizaron dicho curso. Esta diferencia se presentó de manera consistente en las tres áreas evaluadas, lo que permite inferir que la preparación previa puede estar asociada con un mejor desempeño académico. No obstante, este análisis únicamente evidencia una relación entre las variables y no permite afirmar que el curso sea la causa directa del incremento en los puntajes, ya que pueden intervenir otros factores no considerados dentro del conjunto de datos.

4.4.2 Relación entre el género y el rendimiento académico

El análisis realizado por género mostró diferencias en los puntajes promedio entre estudiantes masculinos y femeninos. Se observó que las estudiantes obtuvieron mejores resultados promedio en lectura y escritura, mientras que los estudiantes presentaron un comportamiento similar o ligeramente superior en matemáticas. Estas diferencias coinciden con los resultados observados en el conjunto de datos, aunque no representan una ventaja absoluta para alguno de los grupos, sino tendencias generales dentro de la muestra analizada.

4.4.3 Relación entre el nivel educativo de los padres y el rendimiento académico

Al agrupar la información según el nivel educativo de los padres, se identificó una tendencia en la que los estudiantes cuyos padres cuentan con mayores niveles de formación académica presentan, en promedio, mejores puntajes en las tres áreas evaluadas. Aunque esta tendencia no es completamente uniforme para todas las categorías, sí permite observar una posible relación entre el contexto educativo familiar y el desempeño académico de los estudiantes. Sin embargo, al igual que en los análisis anteriores, estos resultados corresponden a una asociación estadística y no permiten establecer una relación de causalidad.

4.5 Conclusiones

El análisis exploratorio realizado permitió comprender la estructura y el comportamiento del conjunto de datos antes de plantear cualquier tipo de modelo predictivo. Durante la revisión se comprobó que el dataset presenta una buena calidad de la información, ya que no contiene valores nulos ni registros duplicados, lo que facilitó el desarrollo del análisis sin necesidad de aplicar procesos adicionales de limpieza.

El estudio de las variables mostró que los puntajes obtenidos por los estudiantes presentan una distribución relativamente estable, aunque con algunos valores atípicos que corresponden a resultados reales y, por tanto, fueron conservados dentro del análisis. Asimismo, las variables categóricas aportaron información importante para comprender el contexto de cada estudiante y permitieron realizar comparaciones entre diferentes grupos.

Finalmente, el análisis de relaciones entre variables permitió identificar tendencias interesantes. Se observó que los estudiantes que realizaron el curso de preparación obtuvieron, en promedio, mejores resultados académicos. También se evidenciaron diferencias en los puntajes según el género y una tendencia que sugiere un mejor desempeño cuando los padres poseen mayores niveles de formación académica. Aunque estas relaciones no permiten establecer causalidad, sí constituyen información valiosa para comprender el comportamiento del conjunto de datos y orientar futuros estudios.

4.6 Posible aplicación de Inteligencia Artificial

A partir de la información disponible, una posible aplicación de Inteligencia Artificial consiste en desarrollar un modelo de aprendizaje supervisado capaz de estimar el desempeño académico de un estudiante utilizando variables como el género, el nivel educativo de los padres, el tipo de alimentación y la realización de un curso de preparación. Un modelo de este tipo podría apoyar a instituciones educativas en la identificación temprana de estudiantes con mayor probabilidad de presentar bajo rendimiento, permitiendo implementar estrategias de acompañamiento académico antes de que se obtengan los resultados finales. Es importante señalar que este modelo tendría un propósito de apoyo a la toma de decisiones y requeriría un conjunto de datos más amplio y representativo para alcanzar un nivel adecuado de precisión y confiabilidad.

Referencias

- McKinney, W. (2022). *Python for Data Analysis* (3.^a ed.). O'Reilly Media.
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.
- Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
- The pandas development team. (2025). *pandas documentation*. <https://pandas.pydata.org/>
- Python Software Foundation. (2025). *Python 3 Documentation*. <https://docs.python.org/3/>
- UNIMINUTO. (2025). *Estudio de caso – Fundamentos de Inteligencia Artificial*. Material de apoyo de la asignatura.
- UNIMINUTO. (2025). *Anexo – Desarrollo del estudio de caso*. Material de apoyo de la asignatura.