

CORPORACIÓN UNIVERSITARIA MINUTO DE DIOS - UNIMINUTO

Fundamentos para IA

Informe de Análisis Exploratorio de Datos

Dataset: Students Performance in Exams

Johan Ramirez López
Andrés Ramírez García

Bogotá, Colombia 2026

1. Introducción

Para la actividad de la semana 2 de Fundamentos para IA elegimos trabajar con el dataset "Students Performance in Exams", disponible en Kaggle. Contiene los resultados de 1.000 estudiantes en tres pruebas - math, reading y writing junto con algunas variables demográficas y socioeconómicas de cada uno. En este informe buscamos entender qué tan bueno es el dataset, revisar cómo se distribuyen sus variables y encontrar relaciones que puedan servir más adelante si se quisiera construir un modelo predictivo con esta información.

2. Metodología

Todo el trabajo se hizo en Google Colab, usando pandas como herramienta principal. Primero importamos la librería, luego cargamos el archivo StudentsPerformance.csv con `pd.read_csv()` y revisamos las primeras filas con `df.head()` para tener una idea inicial de los datos. Después revisamos la estructura del dataset (`df.shape`, `df.columns`, `df.dtypes`) y evaluamos su calidad revisando nulos, duplicados y valores atípicos. Por último, exploramos las variables categóricas y numéricas con `value_counts()` y `describe()`.

[Enlace actividad en Colab](#)

3. Caracterización del dataset

El dataset está compuesto por 1.000 registros (filas) y 8 columnas. Las columnas y sus tipos de datos se resumen en la siguiente tabla:

Columna	Tipo de dato	Descripción
gender	object (texto)	Género del estudiante (female/male)
race/ethnicity	object (texto)	Grupo étnico codificado (group A a E)
parental level of education	object (texto)	Nivel educativo máximo de los padres
lunch	object (texto)	Tipo de almuerzo (standard / free-reduced)
test preparation course	object (texto)	Si completó curso de preparación
math score	int64	Puntaje obtenido en matemáticas (0-100)
reading score	int64	Puntaje obtenido en lectura (0-100)
writing score	int64	Puntaje obtenido en escritura (0-100)

En resumen, el dataset combina 5 variables categóricas y 3 variables numéricas (puntajes enteros entre 0 y 100), lo que permite tanto análisis de frecuencias como análisis estadístico descriptivo.

4. Calidad de datos

4.1 Valores nulos

Con `df.isnull().sum()` se confirmó que ninguna de las 8 columnas presenta valores nulos: el dataset está completo en sus 1.000 registros.

4.2 Duplicados

Con `df.duplicated().sum()` se identificó 0 filas duplicadas. Por lo tanto, no es necesario realizar una limpieza de datos.

4.3 Valores atípicos (outliers)

Se aplicó el método del rango intercuartílico ($IQR = Q3 - Q1$, con límites $Q1 - 1.5 \cdot IQR$ y $Q3 + 1.5 \cdot IQR$) sobre las tres variables numéricas:

Variable	Q1	Q3	IQR	Límite inferior	Outliers detectados
math score	57	77	20	27.0	8
reading score	59	79	20	29.0	6
writing score	57.75	79	21.25	25.9	5

Los outliers corresponden en su totalidad al extremo inferior ósea puntajes muy bajos, incluyendo un caso con 0 en math score); no se detectaron valores por encima del límite superior, lo cual es consistente con un puntaje máximo de 100. Estos casos no se eliminan, ya que representan desempeños reales y no corresponde a errores en la data. Se deben marcar y tener en cuenta si se realiza un análisis posterior.

5. Análisis exploratorio inicial

5.1 Variables categóricas

Gender, 51.8% mujeres 518 y 48.2% hombres 482; una distribución homogénea del dataset.

Test preparation course, 64.2% de los estudiantes no realizó el curso ("none", 642 casos) frente a 35.8% que sí lo completó ("completed" 358 casos).

Lunch, usado como indicador socioeconómico: 64.5% standard y 35.5% free/reduced.

5.2 Variables numéricas

Estadístico	math score	reading score	writing score
Media	66.09	69.17	68.05
Mediana	66	70	69
Mínimo	0	17	10
Máximo	100	100	100
Desv. Estandar	15.16	14.60	15.20

Las tres pruebas presentan medias y medianas parecidas, con desviaciones estándar cercanas a los 15 puntos, lo que sugiere una dispersión moderada y similar entre las tres materias.

6. Relaciones relevantes entre variables

Correlación entre puntajes: reading score y writing score están fuertemente correlacionados ($r = 0.95$); math score también se correlaciona bien con reading ($r = 0.82$) y writing ($r = 0.80$). Esto nos hace pensar que detrás de los tres puntajes hay un factor común de habilidad académica general, más que tres competencias totalmente independientes.

Curso de preparación vs. puntajes: quienes tomaron el curso obtuvieron en promedio mejores resultados en las tres pruebas (matemáticas 69.7 vs. 64.1; lectura 73.9 vs. 66.5; escritura 74.4 vs. 64.5). La diferencia más grande se ve en escritura, con 9.9 puntos.

Tipo de almuerzo vs. puntajes: los estudiantes con almuerzo standard superan a los de free/reduced en las tres materias (matemáticas 70.0 vs. 58.9; lectura 71.7 vs. 64.7; escritura 70.8 vs. 63.0). Esta es la brecha más amplia que encontramos en todo el dataset, y probablemente refleja el peso del nivel socioeconómico.

Nivel educativo de los padres vs. puntajes: hay una tendencia clara y consistente: a mayor parental level of education, mejores puntajes. Los hijos de padres con master's degree tienen los promedios más altos (math score 69.7, reading 75.4, writing 75.7), mientras que los de padres con some high school o high school quedan más abajo (math entre 62 y 63).

7. Respuestas a las preguntas del informe final

a. ¿Qué fenómeno, proceso o contexto representa el dataset?

Representa el desempeño académico de 1.000 estudiantes en tres pruebas estandarizadas, junto con algunos factores demográficos y socioeconómicos que podrían estar influyendo en esos resultados: gender, race/ethnicity, parental level of education, lunch (como aproximación al ingreso familiar o socioeconómico) y si el estudiante tomó un test preparation course.

b. ¿Cuáles son las 5 variables más importantes para describir el caso y por qué?

- math score, reading score y writing score: son las tres variables objetivo; representan el resultado académico que se busca explicar o predecir.
- test preparation course: es la única variable de intervención directa presente en el dataset; permite evaluar el efecto de una política educativa concreta.
- parental level of education: captura el contexto familiar, uno de los predictores donde se observada mayor diferencia en los promedios.

c. ¿Qué hallazgos se observan en la distribución de variables?

En las categóricas, gender está balanceado, pero test preparation course (64% - 36%) y lunch (64.5% - 35.5%) no lo están, algo que hay que tener presente al comparar grupos. En las numéricas, las tres pruebas se distribuyen de forma bastante simétrica, con medias y medianas cercanas, un techo en 100 y una cola inferior un poco más larga, coherente con los outliers bajos que ya mencionamos.

d. ¿Qué relación relevante encontraron entre las variables? (mínimo 2)

Primero, una correlación positiva fuerte entre los tres puntajes, sobre todo entre lectura y escritura ($r = 0.95$), que apunta a una habilidad académica de base compartida. Segundo, el tipo de almuerzo está asociado a diferencias de hasta 11 puntos entre grupos, la brecha más grande que identificamos en todo el dataset.

e. ¿Qué problemas de calidad de datos detectaron y cómo los abordan?

No se detectaron valores nulos ni registros duplicados, por lo que no fue necesaria limpieza en ese sentido. Sí se identificaron entre 5 y 8 valores atípicos por variable (método IQR), todos en el extremo inferior de la escala. Dado que corresponden a desempeños reales y no a errores de captura (los valores están dentro del rango válido 0-100), se decidió conservarlos en el análisis

exploratorio y solo marcarlos para tratamiento diferenciado si se avanza hacia un modelo predictivo.

f. ¿Qué pregunta de IA o problema predictivo podría plantearse a futuro?

Un problema de regresión para predecir el puntaje de math score, reading score o writing score a partir de las variables demográficas y del test preparation course, o alternatively un problema de clasificación binaria para predecir si un estudiante aprobará o no un umbral mínimo (por ejemplo, puntaje ≥ 60) según su perfil socioeconómico y académico. También sería viable un ejercicio de clustering para segmentar perfiles de estudiantes según patrones combinados de desempeño y contexto.

8. Conclusiones

El dataset Students Performance in Exams es un conjunto de datos limpio (sin nulos ni duplicados) y adecuado para un análisis exploratorio ya que es un conjunto de datos limpio. El hallazgo más relevante es la asociación consistente entre variables de contexto socioeconómico (lunch, parental level of education) y el desempeño académico, así como el efecto positivo medible del test preparation course. Estos resultados sientan una base sólida para plantear, en una fase posterior, modelos de regresión o clasificación que permitan anticipar el desempeño estudiantil y orientar intervenciones educativas.

9. Bibliografía

Tukey, J. W. (1977). Exploratory data analysis. Addison-Wesley.

The pandas development team. (2024). pandas: Powerful data structures for data analysis in Python (Versión 2.x) [Software]. <https://pandas.pydata.org/>

Google. (s.f.). Google Colaboratory [Software].
<https://colab.research.google.com/>

spscientist. (2018). Students performance in exams [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>