

Estudio de Caso: Análisis del Rendimiento Académico de Estudiantes mediante Python y
Archivos CSV

César Augusto Rico Morales

Asesor

César Alfonso Bolado Silva

Corporación Universitaria Minuto De Dios

Fundamentos Para IA

Programa

2026

Introducción

El análisis de datos se ha convertido en una herramienta fundamental para comprender escenarios diferentes y apoyar la toma de decisiones basada en evidencia. En este estudio de caso se emplea Python para analizar un conjunto de datos en formato CSV relacionado con el rendimiento académico de estudiantes. A través de técnicas de exploración y análisis descriptivo, se busca identificar posibles relaciones entre variables demográficas, familiares y educativas con los resultados obtenidos en matemáticas, lectura y escritura.

1. Objeto de estudio

El presente estudio de caso se centra en el análisis de un conjunto de datos almacenado en formato CSV que contiene información sobre el desempeño académico de estudiantes en las áreas de matemáticas, lectura y escritura. Además de las calificaciones obtenidas, el conjunto de datos incorpora variables relacionadas con características demográficas, familiares y educativas, como el género, el grupo étnico, el nivel educativo de los padres, el tipo de alimentación escolar y la participación en cursos de preparación para exámenes.

La situación que se pretende analizar consiste en identificar posibles relaciones entre estas variables y el rendimiento académico de los estudiantes. Para ello, se empleará Python como herramienta de análisis de datos, aprovechando su capacidad para leer, procesar y explorar información contenida en archivos CSV.

El análisis permitirá determinar si factores como el nivel educativo de los padres, el acceso a alimentación escolar estándar o subsidiada y la realización de cursos de preparación tienen algún impacto en el desempeño académico de los estudiantes. Asimismo, se pretende identificar tendencias y diferencias entre grupos que contribuyan a comprender mejor los factores asociados al éxito académico.

2. Actores y contextos

Actores:

Estudiantes

Su rendimiento académico está representado por las variables:

- Math Score
- Reading Score
- Writing Score

Estas variables reflejan el desempeño alcanzado por cada estudiante en diferentes competencias académicas.

Padres de familia

Los padres participan indirectamente a través de la variable "Parental Level of Education", la cual describe su nivel educativo. Este factor puede influir en el acompañamiento académico y en las oportunidades educativas disponibles para los estudiantes.

Instituciones educativas

Representan el entorno donde se desarrollan los procesos de enseñanza y evaluación. Aunque el dataset no identifica una institución específica, las variables relacionadas con alimentación escolar y preparación para pruebas sugieren la existencia de programas educativos de apoyo.

Analista de datos

Es la persona encargada de utilizar Python para explorar, limpiar, visualizar e interpretar la información contenida en el archivo CSV con el fin de generar conclusiones fundamentadas.

Contexto tecnológico

El análisis se desarrollará utilizando Python como lenguaje de programación principal. Para la manipulación y exploración de los datos se empleará la biblioteca Pandas, mientras que Google Colab servirá como entorno de desarrollo y ejecución, permitiendo realizar el procesamiento del archivo CSV de forma eficiente y accesible.

3. Objetivos

Objetivo general

Aplicar Python para leer, procesar y analizar un archivo CSV con información académica de estudiantes, con el propósito de identificar relaciones entre variables demográficas, familiares y educativas, y el rendimiento obtenido en matemáticas, lectura y escritura.

Objetivos específicos

1. Importar y explorar el conjunto de datos utilizando Python y la biblioteca Pandas.
2. Identificar las características principales de las variables incluidas en el dataset.
3. Analizar la distribución de estudiantes según género, nivel educativo de los padres, tipo de alimentación y preparación para exámenes.
4. Evaluar la relación existente entre estas variables y las calificaciones obtenidas.
5. Detectar tendencias y patrones que permitan explicar diferencias en el rendimiento académico.
6. Interpretar los resultados obtenidos mediante estadísticas descriptivas y representaciones gráficas.

Análisis realizado en Google Colab

El análisis exploratorio de datos fue desarrollado en Google Colab utilizando Python y la biblioteca Pandas. Durante el proceso se realizó la lectura y exploración del archivo CSV, la identificación de tipos de datos, el análisis de valores nulos, la detección de valores atípicos y el estudio de la distribución de variables numéricas y categóricas. Asimismo, se evaluaron posibles relaciones entre variables demográficas, familiares y académicas mediante estadísticas descriptivas y visualizaciones gráficas. Los resultados obtenidos permitieron identificar patrones relevantes asociados al rendimiento académico de los estudiantes.

Link de entrega para la revisión de los datos en el ambiente Colab:

<https://colab.research.google.com/drive/1wwJd1FydyUk1Z7kL5lyjHd-rws3jS3?usp=sharing>

Imágenes de soporte para el desarrollo:

```
import kagglehub
from kagglehub import KaggleDatasetAdapter
file_path = "StudentsPerformance.csv"
df = kagglehub.load_dataset(
    KaggleDatasetAdapter.PANDAS,
    "spcscientist/students-performance-in-exams",
    file_path,
)

... /tmp/ipykernel_3889/2767373062.py:4: DeprecationWarning: Use dataset_load() instead of load_dataset(). load_dataset() will be removed in a future version.
df = kagglehub.load_dataset(
Using Colab cache for faster access to the 'students-performance-in-exams' dataset.
```

```
print("tamaño", df.shape)

... tamaño (1000, 8)
```

```
print("Nombre de columnas", df.head(0))

Nombre de columnas Empty DataFrame
Columns: [gender, race/ethnicity, parental level of education, lunch, test preparation course, math score, reading score, writing score]
Index: []
```

```
print("Tipos de datos", df.info(1))

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 8 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   gender                1000 non-null  object
1   race/ethnicity         1000 non-null  object
2   parental level of education 1000 non-null  object
3   lunch                 1000 non-null  object
4   test preparation course 1000 non-null  object
5   math score            1000 non-null  int64
6   reading score         1000 non-null  int64
7   writing score          1000 non-null  int64
dtypes: int64(3), object(5)
memory usage: 62.6+ KB
Tipos de datos None
```

```
df["gender"].value_counts()
df["gender"].value_counts(normalize=True) * 100
```

```
proportion

gender
female    51.8
male      48.2
```

```
dtype: float64
```

Conclusión

El presente estudio permitió evidenciar la utilidad de Python como herramienta para la lectura, procesamiento y análisis de datos almacenados en archivos CSV. A través de la exploración del conjunto de datos seleccionado fue posible identificar variables relevantes relacionadas con el rendimiento académico estudiantil y comprender cómo factores personales, familiares y educativos pueden estar asociados con los resultados obtenidos en matemáticas, lectura y escritura. Asimismo, se destacó la importancia de herramientas como Pandas y Google Colab para facilitar el análisis de datos y apoyar la generación de conocimiento a partir de la información disponible. Finalmente, este ejercicio demuestra el valor de la ciencia de datos en la comprensión de fenómenos educativos y en la toma de decisiones fundamentadas en evidencia.

Referencias

Boschetti, A., & Massaron, L. (2018). Python data science essentials: A practitioner's guide covering essential data science principles, tools, and techniques. Packt Publishing.

Google. (s. f.). Google Colaboratory. <https://colab.research.google.com/>

Kaggle. (s. f.). Students Performance in Exams.
<https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>

Pandas Development Team. (s. f.). Pandas documentation. <https://pandas.pydata.org/docs/>

So, A., Joseph, T. V., John, R. T., Worsley, A., & Asare, S. (2020). The data science workshop: A new, interactive approach to learning data science. Packt Publishing.