

Taller: Librerías de Python para inteligencia artificial

Análisis del dataset Netflix TV Shows and Movies (credits.csv) con NumPy, SciPy, Matplotlib y Seaborn

Curso: Fundamentos para Inteligencia Artificial (NRC 94103)

Institución: Universidad Minuto de Dios (UNIMINUTO)

Docente: Ing. César Alfonso Bolado Silva

Actividad: Semana 4 – Taller colaborativo

Elaborado por: _____

Fecha de entrega: Julio de 2026

1. Reconocimiento de *frameworks* de IA en Python

Un framework es una estructura de trabajo que impone una arquitectura y un flujo determinado al programa (por ejemplo, definir las capas de una red neuronal siguiendo reglas propias del framework), mientras que una librería es un conjunto de funciones reutilizables que se invocan libremente, sin imponer una estructura al programa completo.

Cuatro frameworks/librerías comunes en inteligencia artificial:

- Scikit-learn: librería de machine learning clásico para clasificación, regresión, clustering y preprocesamiento de datos.
- TensorFlow: framework para construir y entrenar redes neuronales y modelos de deep learning a gran escala.
- PyTorch: framework de deep learning flexible, muy usado en investigación, visión por computador y procesamiento de lenguaje natural.
- Hugging Face (Transformers): librería/ecosistema de modelos preentrenados para procesamiento de lenguaje natural (NLP) y otras tareas.

Estas herramientas se usan en tareas de clasificación, regresión, visión por computador, procesamiento de lenguaje natural (NLP) y clustering, entre otras.

2. Selección, carga y preparación del *dataset*

Se utilizó el dataset Netflix TV Shows and Movies (Soeiro, 2022), específicamente el archivo `credits.csv`, que contiene el reparto (actores) y la dirección (directores) de 5 489 títulos disponibles en Netflix, con un total de 77 801 registros de crédito.

2.1 Estructura original

El archivo se cargó con pandas (`read_csv`). `df.shape` reporta 77 801 filas y 5 columnas; `df.info()` confirma los tipos: `person_id` (entero), `id`, `name`, `character` y `role` (texto).

Variable	Descripción
<code>person_id</code>	Identificador numérico de la persona (actor o director)
<code>id</code>	Identificador del título de Netflix
<code>name</code>	Nombre de la persona
<code>character</code>	Personaje interpretado (solo aplica a actores)
<code>role</code>	Rol de la persona en el título: ACTOR o DIRECTOR

El dataset original no trae variables numéricas de medida (solo identificadores), por lo que fue necesario construir variables numéricas derivadas mediante agregación, tal como permite el enunciado del taller.

2.2 Calidad de datos y decisiones de limpieza

- Valores nulos: character tiene 9 772 valores nulos (12.6% de las filas), correspondientes a registros donde role = DIRECTOR, ya que un director no interpreta un personaje. No es un error de captura, por lo que se imputó con el texto "Sin especificar" en lugar de eliminar la fila, evitando perder información válida sobre el director.
- Duplicados: `df.duplicated().sum()` reportó 0 filas duplicadas.
- Formato: la columna role se convirtió al tipo category. person_id e id se mantuvieron como identificadores (llaves de agregación), no como variables numéricas de análisis.

2.3 Variables seleccionadas para el análisis

- tamaño_reparto (numérica, por título): número de personas distintas acreditadas (actores + director) en cada título, obtenida con `df.groupby('id')['person_id'].nunique()`.
- títulos_por_persona (numérica, por persona): número de títulos distintos en los que aparece cada persona, obtenida con `df.groupby('person_id')['id'].nunique()`.
- role / rol_principal (categórica): ACTOR o DIRECTOR.

Adicionalmente se construyó una tabla por título con el número de actores y de directores por separado (actors, directors), usada en el análisis de correlación (sección 4).

2.4 Tratamiento de valores atípicos

Los atípicos de tamaño_reparto se identificaron con puntuación z en la sección 4 (SciPy), pues afectan directamente la media y la forma del histograma (sección 5). Se decidió conservarlos, documentándolos: corresponden a talk shows y series de formato de concurso o telerrealidad con reparto rotativo muy numeroso (nombres reales, no errores de captura). Para su visualización se aplicó una transformación logarítmica (sección 5.2).

3. Implementación con NumPy (cálculo y transformación)

Se aplicaron cuatro acciones de NumPy sobre las variables numéricas derivadas:

- 1) Conversión de la columna tamaño_reparto a un arreglo de NumPy (`np.array`) de 5 489 elementos.
- 2) Estadísticos descriptivos: media = 14.10, mediana = 10.00, percentiles [25, 50, 75, 90, 95] = [5, 10, 18, 30, 43].
- 3) Operación vectorizada sin ciclos: estandarización z-score manual, $z = (x - \text{media}) / \text{desviación estándar}$; se identificaron 108 títulos con $z > 3$.
- 4) `np.unique` con conteos sobre la variable categórica role: 73 251 créditos de ACTOR (94.15%) y 4 550 de DIRECTOR (5.85%).

Interpretación: el reparto promedio por título es de aproximadamente 14 personas, pero la mediana (10) es notablemente menor que la media, lo que evidencia una distribución sesgada a la derecha: algunos títulos con reparto muy numeroso elevan el promedio. Los percentiles lo confirman: el 75% de los títulos tiene 18 personas o menos, pero el percentil 95 llega a 43. La estandarización vectorizada permitió identificar, sin ciclos for, los títulos que superan 3 desviaciones estándar por encima del promedio.

4. Implementación con SciPy (análisis / estadística)

Se aplicaron los siguientes procedimientos de `scipy.stats`:

- Prueba de normalidad (Shapiro-Wilk) sobre una muestra de 5 000 valores de `tamano_reparto`: estadístico = 0.719, $p < 0.001$. Se rechaza la normalidad.
- Correlación entre número de actores y número de directores por título: Pearson $r = 0.159$ ($p < 0.001$); Spearman $\rho = 0.229$ ($p < 0.001$).
- Puntuación z (`scipy.stats.zscore`) para detección de atípicos en `tamano_reparto`: 108 títulos con $|z| > 3$ (p. ej., un título con 208 personas acreditadas frente a una media de 14).
- Prueba t de Welch comparando `titulos_por_persona` entre actores (media = 1.42, $n = 51\,468$) y directores (media = 1.35, $n = 3\,121$): $t = 3.70$, $p = 0.0002$.

Interpretación: dado que Shapiro-Wilk rechaza la normalidad de `tamano_reparto` ($p < 0.05$), se dio más peso al coeficiente de Spearman (0.229) que al de Pearson (0.159) al interpretar la relación entre actores y directores por título: la asociación es positiva pero débil. La prueba t de Welch mostró una diferencia estadísticamente significativa ($p < 0.001$) entre el número promedio de títulos por persona de actores y de directores: en promedio, los actores acreditados aparecen en ligeramente más títulos distintos.

5. Visualización con Matplotlib

Se elaboraron cuatro gráficas distintas con Matplotlib, pertinentes a las variables numéricas y categórica seleccionadas:

5.1 Histograma de `tamano_reparto`




Figura 1. Distribución del tamaño de reparto por título (Matplotlib).

Confirma visualmente el sesgo a la derecha detectado con NumPy: la mayoría de los títulos tiene reparto pequeño, con una cola larga de títulos con reparto muy numeroso.

5.2 Dispersión: actores vs. directores por título




Figura 2. Número de actores vs. número de directores por título (Matplotlib).

La nube de puntos muestra que la mayoría de los títulos tiene 1 o 2 directores, independientemente del tamaño del reparto de actores, lo cual es coherente con la correlación débil calculada en SciPy.

5.3 Boxplot: títulos por persona según rol principal




Figura 3. Títulos por persona según rol principal (Matplotlib).

Ambos grupos muestran una mediana de 1 título por persona, con una cola de valores atípicos hacia arriba (personas muy prolíficas), más marcada en el grupo de actores.

5.4 Barras: distribución de la variable categórica rol




Figura 4. Distribución de créditos por rol (Matplotlib).

Se confirma visualmente el desbalance: los créditos de ACTOR (94.15%) superan ampliamente a los de DIRECTOR (5.85%), lo esperable dado que cada título suele tener un solo director frente a un reparto más numeroso.

6. Visualización con Seaborn

Se elaboraron cuatro gráficas distintas con Seaborn, repitiendo y complementando el análisis visual anterior:

6.1 Distribución de $\log(1 + \text{tamano_reparto})$




Figura 5. Distribución de $\log(1 + \text{tamaño de reparto})$, con curva de densidad (Seaborn).

La transformación logarítmica reduce el efecto de los atípicos y permite ver con más claridad la forma general de la distribución, con la curva de densidad (kde) superpuesta automáticamente por Seaborn.

6.2 Violinplot: títulos por persona según rol principal




Figura 6. Títulos por persona según rol principal (Seaborn).

El violinplot añade a la información del boxplot la forma de la densidad de cada grupo, mostrando que la gran mayoría de personas (actores y directores) aparece en un solo título.

6.3 Dispersión con línea de tendencia: actores vs. directores




Figura 7. Número de actores vs. número de directores por título, con línea de tendencia (Seaborn).

regplot agrega automáticamente una línea de tendencia con intervalo de confianza, evidenciando la relación positiva pero débil ya cuantificada con Spearman.

6.4 Mapa de calor de correlación




Figura 8. Correlación entre variables numéricas por título (Seaborn).

El heatmap resume en una sola imagen las correlaciones entre actores, directores y tamaño_reparto (esta última correlaciona casi perfectamente con actores por construcción, ya que la mayoría del reparto son actores).

6.5 Comparación Matplotlib vs. Seaborn

Para el histograma y el scatterplot, Matplotlib exige definir manualmente cada elemento (bins, colores, título), mientras que Seaborn ofrece por defecto una estética más cuidada y funciones de alto nivel como regplot (línea de tendencia automática) o histplot(kde=True) (curva de densidad superpuesta) que en Matplotlib requerirían varias líneas adicionales. El heatmap de Seaborn, en particular, no tiene un equivalente directo tan simple en Matplotlib puro, donde habría que combinar imshow con anotaciones manuales de texto.

7. Respuestas a las preguntas del taller

7.1 ¿Qué fenómeno, proceso o contexto representa el dataset?

El dataset representa la composición del reparto (actores) y la dirección de 5 489 títulos de Netflix (películas y series), es decir, quién participó en cada producción y en qué calidad (actor o director), permitiendo estudiar patrones como el tamaño de los repartos, la carrera de las personas acreditadas (en cuántos títulos aparecen) y la relación entre el número de actores y de directores por producción.

7.2 ¿Cuáles son las 5 variables más importantes para describir el caso y por qué?

#	Variable	Tipo	Por qué es importante
1	role	Categórica	Distingue el tipo de participación (ACTOR/DIRECTOR); es la base para construir

#	Variable	Tipo	Por qué es importante
			el resto de variables derivadas y para segmentar el análisis.
2	tamano_reparto	Numérica (derivada)	Cuantifica cuántas personas participan en cada título; es la variable central del análisis de NumPy, SciPy y de las visualizaciones.
3	títulos_por_persona	Numérica (derivada)	Aproxima la trayectoria/productividad de cada persona en la plataforma; permitió comparar actores y directores con la prueba t.
4	id	Identificador / categórica	Es la llave que permite agregar los créditos por título y calcular tamano_reparto y el número de actores/directores por título.
5	character	Categórica (texto libre)	Indica si la persona interpretó un papel o no (nulo en directores); fue clave para el diagnóstico de calidad de datos (sección 2.2).

7.3 ¿Qué hallazgos se observan en la distribución de variables (categóricas y numéricas)?

En la variable categórica role, existe un fuerte desbalance: 94.15% de los créditos son de ACTOR frente a 5.85% de DIRECTOR, coherente con que cada título tiene en promedio un reparto mucho más numeroso que su equipo de dirección. En las variables numéricas derivadas, tamano_reparto tiene una distribución sesgada a la derecha (media = 14.10, mediana = 10.00, máximo = 208) y no pasa la prueba de normalidad de Shapiro-Wilk ($p < 0.001$); títulos_por_persona está aún más concentrada, con mediana de 1 título por persona (75% de las personas aparece en un solo título) y una cola de personas muy prolíficas (hasta 25 títulos).

7.4 ¿Qué relación relevante encontraron entre las variables? (mínimo 2)

- Existe una correlación positiva pero débil entre el número de actores y el número de directores por título (Spearman rho = 0.229, $p < 0.001$; Pearson r = 0.159): los títulos con reparto de actores más numeroso tienden, levemente, a tener también más directores acreditados (por ejemplo, series con varios episodios dirigidos por personas distintas).
- El número de títulos por persona difiere de forma estadísticamente significativa entre actores y directores (prueba t de Welch, $t = 3.70$, $p = 0.0002$): los actores acreditados aparecen, en promedio, en un número ligeramente mayor de títulos distintos (1.42) que los directores (1.35).

7.5 ¿Qué problemas de calidad de datos detectaron y cómo los abordan?

Se detectaron 9 772 valores nulos en la columna character (12.6% de las filas), correspondientes en su totalidad a registros de directores; se abordó imputándolos con el texto "Sin especificar" en lugar de eliminarlos, ya que la ausencia de personaje es información esperada para ese rol y no un error. No se encontraron filas duplicadas. Adicionalmente, se detectaron 108 títulos con un tamaño de reparto atípico ($|z| > 3$ con scipy.stats.zscore, hasta 208 personas en un mismo título); se decidió conservarlos por representar casos reales (talk shows y series de telerrealidad con reparto rotativo), documentándolos y aplicando una transformación logarítmica para su visualización en lugar de eliminarlos.

7.6 Con base en lo observado, ¿qué pregunta de IA o problema predictivo podría plantearse a futuro con este dataset?

Se podría plantear un problema de clasificación para predecir el rol (ACTOR/DIRECTOR) de una persona a partir de variables como el número de títulos en los que participa o características del texto del campo

character. También sería posible un problema de regresión para predecir el tamaño de reparto (tamano_reparto) de un título nuevo a partir de atributos adicionales del catálogo (que requerirían cruzar este archivo con titles.csv del mismo dataset de Kaggle, con año, género y duración). Finalmente, un análisis de clustering podría usarse para segmentar perfiles de personas (por número de títulos y tipo de rol) y así, por ejemplo, identificar patrones de colaboración recurrente entre actores y directores.

8. Pensamiento crítico

8.1 ¿Cuándo conviene usar Matplotlib y cuándo Seaborn?

Matplotlib conviene cuando se necesita control total sobre cada elemento de la gráfica —por ejemplo, el gráfico de barras de la sección 5.4, donde se definieron colores y ticks a la medida— o para gráficas simples y rápidas. Seaborn conviene cuando se trabaja directamente con un DataFrame y se quieren gráficas estadísticas ya elaboradas, como el heatmap de correlación (sección 6.4) o el regplot con línea de tendencia (sección 6.3), que en Matplotlib tomarían mucho más código.

8.2 ¿Qué ventajas aporta NumPy frente a trabajar solo con Pandas?

NumPy permite operaciones vectorizadas de bajo nivel —como la estandarización z-score de la sección 3— sin escribir ciclos for, con mejor rendimiento sobre arreglos grandes, y ofrece funciones numéricas (percentiles, unique con conteos) que Pandas reutiliza internamente. Además, muchas librerías de IA (scikit-learn, TensorFlow, PyTorch) reciben arreglos de NumPy como entrada estándar.

8.3 ¿Qué aportó SciPy que no era tan directo con NumPy/Pandas?

SciPy aportó pruebas estadísticas formales con su propio p-valor (Shapiro-Wilk para normalidad, prueba t de Welch) que NumPy no calcula directamente, y funciones específicas como zscore y spearmanr que, de no usar SciPy, habría sido necesario programar manualmente con NumPy/Pandas.

8.4 Si el objetivo fuera construir un modelo de IA (predicción), ¿qué herramienta sumarían y por qué?

Se sumaría scikit-learn, ya que provee de forma directa algoritmos de clasificación y regresión, herramientas de partición de datos (train_test_split) y de evaluación de modelos, construidas justamente sobre los arreglos de NumPy y los DataFrames de Pandas ya preparados en este taller.

8.5 ¿Qué limitaciones detectaron en su dataset para aplicar análisis estadístico o visual?

El archivo credits.csv no trae variables numéricas de medida originales (solo identificadores), por lo que fue necesario construir variables derivadas (tamano_reparto, titulos_por_persona) mediante agregación. Tampoco incluye información temporal, de género/categoría del título ni de calificación, lo que limita el análisis a la composición del reparto y no permite relacionar, por ejemplo, el tamaño del reparto con el año de lanzamiento o el tipo de contenido sin cruzar este archivo con titles.csv, del mismo dataset de Kaggle.

Referencias bibliográficas

Boschetti, A. y Massaron, L. (2018). Python Data Science Essentials: A Practitioner's Guide Covering Essential Data Science Principles, Tools, and Techniques (pp. 281-331). Packt Publishing Ltd.

Yim, A., Chung, C., y Yu, A. (2018). Matplotlib for python developers: Effective techniques for data visualization with python (2.^a ed., pp. 21-54). Packt Publishing, Limited.

Fuentes, A. (2018). Become a python data analyst: Perform exploratory data analysis and gain insight into scientific computing using python (pp. 69-118). Packt Publishing, Limited.

Mehta, H. (2015). Mastering Python Scientific Computing (pp. 163-198). Packt Publishing, Limited.

Soeiro, V. (2022). Netflix TV Shows and Movies. Kaggle. <https://www.kaggle.com/datasets/victorsoeiro/netflix-tv-shows-and-movies>

The SciPy community. (2024). SciPy documentation. <https://docs.scipy.org/doc/scipy/>