



SEMANA 4. LIBRERÍAS PARA CÁLCULO NUMÉRICO, ANÁLISIS Y VISUALIZACIÓN DE DATOS

FUNDAMENTOS PARA INTELIGENCIA ARTIFICIAL
Julio 2026

Tabla de Contenido

01. ¿Por qué estas librerías?

04. Matplotlib: visualización

02. NumPy: cálculo numérico

05. Seaborn: gráficos estadísticos

03. SciPy: análisis estadístico

06. Caso práctico: dataset Netflix

01

Experimenta con las librerías Matplotlib y Seaborn

Interpretación operativa: construye visualizaciones de distribución, relación y comparación por categoría que permiten leer con precisión los hallazgos de un dataset.

02

Utiliza las librerías NumPy y SciPy

Interpretación operativa: aplica arreglos, estadísticos y operaciones vectorizadas, y ejecuta procedimientos estadísticos (correlación, normalidad, pruebas de hipótesis) sobre variables numéricas.

¿POR QUÉ NUMPY, SCIPY, MATPLOTLIB Y SEABORN?

01

Cálculo vectorizado

NumPy permite operar arreglos completos sin ciclos for, con mejor rendimiento que Python puro.

02

Estadística aplicada

SciPy aporta pruebas formales (normalidad, correlación, prueba t) que NumPy no calcula directamente.

03

Control total con Matplotlib

Permite definir cada elemento de la gráfica: colores, ejes, anotaciones y estilo, a la medida.

04

Alto nivel con Seaborn

Ofrece gráficas estadísticas ya elaboradas (heatmap, regplot, violinplot) directo sobre un DataFrame.

Arreglo NumPy (np.array)

Convierte una columna del dataset en un arreglo NumPy, la base para cualquier cálculo vectorizado.

```
arr = np.array(datos)
shape: (5489,)
```

Estadísticos descriptivos

Media, mediana y percentiles del tamaño de reparto por título.

```
np.mean, np.median,
np.percentile
```

Operación vectorizada

Estandarización z-score sin ciclos for, para detectar reparto atípico.

```
z = (x - x.mean()) / x.std()
```

Una 4.ª acción, np.unique con conteos, describe role: 94% actores y 6% directores.

- 1 Shapiro-Wilk: prueba de normalidad sobre `tamano_reparto` ($p < 0.001$, no es normal)
- 2 Correlación Spearman entre actores y directores por título ($\rho = 0.229$)
- 3 Puntuación z (zscore) para detectar 108 títulos con reparto atípico
- 4 Prueba t de Welch: compara títulos por persona entre actores y directores ($p < 0.001$)

```
stats.zscore(tamano_reparto)
108 títulos con  $|z| > 3$ 
```

MATPLOTLIB: VISUALIZACIÓN DE DATOS

hist — histograma de una variable numérica (ej. tamaño de reparto)

scatter — dispersión entre dos numéricas (actores vs. directores)

boxplot — comparación de una variable numérica por categoría

bar — distribución de una variable categórica (ACTOR vs. DIRECTOR)

Mínimo 3 gráficas distintas, pertinentes a las variables del dataset.

```
plt.hist(tamano_reparto, bins=40)
plt.title('Reparto por título')
plt.xlabel('Personas')
plt.ylabel('Frecuencia')

plt.show()
→ sesgo a la derecha (media 14, mediana 10)
```

```
sns.histplot(np.log1p(reparto), kde=True)
plt.title('log(reparto)')
sns.violinplot(x=rol, y=titulos)
sns.regplot(x='actors', y='directors',
            data=por_titulo)

sns.heatmap(corr, annot=True,
            cmap='coolwarm')

plt.show()
→ Spearman rho = 0.229
→ 4 gráficas Seaborn distintas
```

Estética automática

kde=True agrega una curva de densidad; regplot traza la línea de tendencia sin código adicional.

Mapa de calor de correlación

heatmap resume en una imagen las correlaciones entre variables, algo que en Matplotlib exige combinar imshow con texto manual.

Para el histograma y el scatterplot, Seaborn ofrece por defecto una estética más cuidada que Matplotlib.

CASO PRÁCTICO: DATASET DE NETFLIX (credits.csv)

```
df = pd.read_csv('credits.csv')
df.groupby('id')['person_id']
    .nunique()

df.shape
(77801, 5)
```

person_id / name — identifican a cada actor o director acreditado

id — identifica el título de Netflix (película o serie)

character / role — personaje interpretado (solo actores) y tipo de rol

El dataset no trae variables numéricas de medida: tamaño_reparto y títulos_por_persona se construyen por agregación.

ACTIVIDAD PRÁCTICA DEL TALLER

1

Preparar datos — cargar credits.csv, revisar nulos/duplicados y construir las variables numéricas derivadas.

2

Aplicar librerías — usar NumPy y SciPy para calcular estadísticos y pruebas; Matplotlib y Seaborn para graficar.

3

Responder y entregar — documentar hallazgos, responder las preguntas del taller y subir notebook e informe en Word.

Soeiro, V. (2022). *Netflix TV Shows and Movies.*

Kaggle — dataset de reparto y dirección utilizado en el caso práctico de esta sesión.

Yim, A., Chung, C., y Yu, A. (2018). *Matplotlib for python developers.*

Packt Publishing — técnicas de visualización de datos con Python (pp. 21-54).

Boschetti, A. y Massaron, L. (2018). *Python Data Science Essentials.*

Packt Publishing — principios y técnicas esenciales de ciencia de datos (pp. 281-331).

ENTREGABLE Y CRITERIOS DE EVALUACIÓN

Entregable: notebook (Colab/Jupyter) con el análisis y un informe en Word con hallazgos y respuestas, subidos antes de la próxima sesión.



NumPy y SciPy — mínimo 4 acciones y 2 procedimientos aplicados e interpretados.



Matplotlib y Seaborn — mínimo 3 gráficas distintas por librería, con interpretación.



Preguntas del caso — respondidas con evidencia de tablas, cálculos y gráficas.



UNIMINUTO
Corporación Universitaria Minuto de Dios
Educación de calidad al alcance de todos

Rectoría UNIMINUTO Virtual



GRACIAS

Educamos sin fronteras transformándonos para el futuro con

CALIDAD Y CALIDEZ

www.uniminuto.edu/uniminuto-virtual



70
Años